Organisation et répartition des travaux

Plateforme intelligente d'AutoML et de Deep Learning assistée par IA générative

Groupe : **5IASDT G1**
Module : **PFA**

Projet de plateforme intelligente ML / DL — Document de concertation. Répartition fonctionnelle des travaux • Version de discussion • Novembre 2026.

Proposition structurée pour quatre étudiants organisés en deux binômes, avec responsabilités individuelles et intégration collective.

> ***Statut :*** *proposition à valider par l'équipe. La durée, les échéances et l'identité des étudiants restent à définir.*

1. Objet du document

Ce document présente une organisation opérationnelle du développement de la plateforme. Il vise une répartition équitable des travaux, une collaboration étroite au sein de deux binômes et la réalisation d'un produit unique et cohérent. Il complète le cahier des charges fonctionnel ; il ne le remplace pas.

2. Principes d'organisation

- Deux binômes complémentaires de deux étudiants ; un responsable identifié pour chacun des quatre sous-systèmes.
- Chaque sous-système comprend des fonctionnalités backend, une partie d'interface utilisateur, des tests et une documentation.
- Un socle technique commun : authentification, gestion des projets, stockage, conventions d'API, supervision des tâches et infrastructure de développement.
- Des interfaces contractuelles stables pour permettre un développement en parallèle et limiter les blocages.
- Un scénario de bout en bout partagé, validé progressivement par toute l'équipe.

3. Vue d'ensemble des binômes

Binôme	Étudiant	Responsabilité dominante
A — Data Intelligence & ML Engineering	**E1**	Compréhension des données, analyse et pipelines de préparation
	E2	Catalogue de modèles, entraînement, optimisation et évaluation
B — Agentic AI & Intelligent Workspace	**E3**	Orchestration IA, compréhension des objectifs et assistant de recherche
	E4	Éditeur visuel de workflows, reproductibilité et cycle de vie des modèles

> ***Remarque :*** *Cette séparation est fonctionnelle et non strictement technologique : aucun étudiant ne devient l'unique responsable de l'ensemble du frontend ou de l'ensemble du backend.*

4. Missions individuelles et livrables

4.1 Étudiant 1 — Intelligent Data Understanding & Pipeline Engineering

Objectif : transformer un dataset brut en un jeu de données compris, contrôlé et préparé, avec des décisions de traitement traçables.

- Importer et valider les fichiers et leurs métadonnées (formats initiaux à préciser : CSV et XLSX en priorité).
- Effectuer le profilage : types, distributions, valeurs manquantes, doublons, cardinalités et déséquilibre éventuel.
- Produire l'analyse exploratoire (EDA), les statistiques et des graphiques interactifs.
- Proposer et exécuter des transformations : imputation, encodage, mise à l'échelle et traitement des variables.
- Mettre en place une séparation correcte entraînement/validation/test et contrôler les risques de fuite de données.
- Exposer des API pour les profils, rapports, transformations et versions de datasets.
- Développer les écrans propres au module et les tests unitaires et d'intégration.

Livrables : moteur de profilage, pipeline de prétraitement reproductible, rapport d'EDA, interfaces et tests.

4.2 Étudiant 2 — Intelligent Model Training & Experimentation

Objectif : permettre la configuration, l'exécution, le suivi et la comparaison reproductibles d'expériences ML/DL.

- Définir un catalogue extensible de modèles et des métadonnées décrivant tâches, paramètres et contraintes.
- Implémenter d'abord des modèles tabulaires de classification/régression et une baseline simple par tâche.
- Fournir une configuration dynamique des hyperparamètres et valider les valeurs saisies.
- Orchestrer les entraînements asynchrones, états des jobs et journaux de progression.
- Intégrer l'optimisation des hyperparamètres (par exemple Optuna) et le suivi des expériences (par exemple MLflow).
- Calculer des métriques adaptées aux tâches, fournir des comparaisons et diagnostics interprétables.
- Prévoir les premières extensions DL et la procédure d'ajout contrôlé de modèles, sans installation arbitraire sur le serveur principal.

Livrables : moteur d'entraînement, catalogue configurable, suivi des expériences, évaluation et tests.

4.3 Étudiant 3 — Agentic AI Orchestration & Research Assistant

Objectif : transformer une intention exprimée en langage naturel en un workflow structuré, vérifiable et explicable.

- Interpréter les objectifs utilisateur et identifier la tâche, la cible et les ambiguïtés à clarifier.

- Proposer un plan ML/DL typé, avec étapes, alternatives, prérequis et points d'approbation.
- Orchestrer les outils du module Data et du module Training via des interfaces documentées.
- Produire des recommandations justifiées à partir de résultats de calcul réels, sans inventer de statistiques.
- Construire un assistant conversationnel pour expliquer profils, métriques, erreurs et possibilités d'amélioration.
- Implémenter les modes automatique, guidé et expert et leurs règles de contrôle.
- Tracer les décisions, validations humaines et échecs ; limiter les actions à des outils autorisés.

Livrables : moteur d'orchestration, assistant de recherche, contrats de plans, règles de validation et tests.

4.4 Étudiant 4 — Visual Workflow Studio & Model Lifecycle

Objectif : rendre les workflows visibles, éditables, exécutables et exportables dans un environnement utilisateur cohérent.

- Concevoir un éditeur visuel des étapes de traitement, entraînement et évaluation (glisser-déposer).
- Afficher les dépendances, paramètres, états d'exécution, erreurs et résultats associés aux nœuds.
- Permettre de modifier puis valider les plans proposés par l'IA avant leur exécution.
- Gérer l'historique des pipelines, leurs versions et la reprise d'expériences.
- Exporter un projet reproductible : code, paramètres, dépendances, rapport et artefacts autorisés.
- Fournir une interface de registre de modèles et de prédiction sur de nouvelles données.
- Préparer, en extension, l'exposition d'un modèle validé via une API d'inférence.

Livrables : éditeur visuel, gestion des versions de workflows, export reproductible, interface du cycle de vie et tests.

5. Interfaces et dépendances intermodules

Émetteur	Récepteur	Contrat / échange attendu
E1 — Data	E2 — Training	Dataset versionné, schéma des variables, partitions et pipeline préparatoire
E1/E2 — Moteurs	E3 — IA	Profils, métriques, erreurs structurées et liste d'opérations admissibles
E3 — IA	E4 — Studio	Plan structuré : nœuds, paramètres, dépendances et autorisations
E4 — Studio	E1/E2 — Exécution	Workflow validé, identifiants de jobs, suivi des états et artefacts
E2 — Training	E4 — Cycle de vie	Version du modèle, métriques, artefacts, statut et informations de reproductibilité

> ***Remarque :*** *Les contrats seront décrits par OpenAPI/Pydantic ou des schémas équivalents. Les appels asynchrones devront utiliser des identifiants de tâches stables et des états explicites (en attente, en cours, terminé, en échec, annulé).*

6. Réalisation du socle partagé

Le socle commun comprend l'authentification, les droits d'accès, les projets, le stockage des datasets et artefacts, la base de données, la gestion des jobs, les conventions de journalisation et les composants graphiques transversaux. Ces éléments sont planifiés et revus collectivement ; un référent tournant peut coordonner chaque chantier, sans concentrer toute la charge sur un seul étudiant.

7. Phasage indicatif sans calendrier figé

Phase	Binôme A	Binôme B	Validation commune
0. Cadrage	Modèles de données et contrats Data/Training	Contrats workflow/IA et parcours utilisateur	Architecture, conventions Git et API approuvées
1. Première tranche	Import/EDA et premier entraînement	Chat minimal et éditeur de pipeline minimal	Parcours dataset → entraînement manuel
2. Intelligence	Prétraitement, métriques et tuning	Plan IA et édition/validation du pipeline	Workflow proposé puis exécuté
3. Enrichissement	Traçabilité, MLflow et premières extensions DL	Assistant de recherche et export de projet	Comparaison + export reproductible
4. Consolidation	Tests de robustesse et performance	Tests UX et gestion des erreurs	Démonstration intégrée et documentation

> ***Remarque :*** *Le contenu détaillé et la profondeur des phases seront ajustés après confirmation de la durée, des ressources CPU/GPU et du niveau des étudiants.*

8. Équité, suivi et contrôle de qualité

Les quatre volets présentent une complexité significative, mais de nature différente. Pour équilibrer les efforts, le périmètre DL de l'étudiant 2 sera progressif ; le frontend transversal et l'infrastructure ne seront pas attribués intégralement à l'étudiant 4. Chaque étudiant doit disposer de livrables visibles, d'une API vérifiable et de tests propres.

- Une réunion courte de synchronisation des binômes et une démonstration collective hebdomadaire.
- Une branche de travail par fonctionnalité, des Pull Requests et une revue par au moins un autre étudiant.
- Des tests automatisés pour chaque module, complétés par des tests d'intégration transversaux.
- Une documentation concise des contrats, décisions, limites connues et procédures de démarrage.
- Des versions de démonstration intégrées régulièrement, plutôt qu'une fusion tardive en fin de projet.

9. Scénario commun de validation de bout en bout

- Un utilisateur crée un projet, importe un dataset tabulaire et décrit un objectif de classification.
- **E1** produit le profil du dataset, les visualisations et un pipeline de prétraitement compatible avec la validation.
- **E3** propose un plan structuré avec modèles candidats, justification et demandes de confirmation.

- **E4** rend le plan visible, autorise son édition et transmet une version approuvée pour exécution.
- **E2** entraîne les modèles, suit les expériences et publie des métriques comparables et des artefacts.
- **E3** explique les résultats à partir des sorties vérifiées, et **E4** permet l'export reproductible du projet.

Critères d'acceptation transversaux : absence de fuite de données dans les traitements, reproductibilité d'une expérience à configuration identique dans les limites du non-déterminisme matériel, gestion explicite des erreurs, journalisation et respect des autorisations.

10. Points à valider par les quatre étudiants

- Validation de la structure des deux binômes et des responsabilités individuelles.
- Choix du périmètre de la première livraison (classification/régression tabulaire en priorité).
- Choix des technologies principales, après vérification des compétences et des ressources disponibles.
- Définition des responsabilités de maintenance du socle commun et des règles de revue.
- Confirmation de la durée, des jalons et du niveau attendu pour les extensions Deep Learning.

> ***Conclusion :*** *La proposition recherche un équilibre entre autonomie individuelle et travail collectif. Son efficacité dépend d'un découpage par capacités métier, de contrats d'intégration précoces et d'une validation continue du parcours utilisateur complet.*